

Логистическая регрессия

Лекция 6

Елена Тутубалина

Казанский федеральный университет

22 марта 2018 г.

Введение

Логистическая регрессия (или метод максимальной энтропии MaxEnt) относится к семейству логарифмически-линейных классификаторов.

- ▶ как и НБ применяется линейная комбинация взвешенных признаков
- ▶ НБ - генеративная модель, MaxEnt – дискриминативная.

Генеративная модель

Классификатор НБ:

$$\hat{y} = \operatorname{argmax}_y P(y|x) = \operatorname{argmax}_y P(x|y)P(y)$$

- ▶ оценивается генерация x из класса y
- ▶ правдоподобие признаков x при заданном y

Дискриминативная модель

- ▶ вычисляем $P(y|x)$ напрямую
- ▶ проводим различия между значениями y
- ▶ извлекаем признаки, комбинируем их, применяем функцию

Линейная комбинация 1

$$P(y = C|x) = \sum_{i=1}^N w_i f_i = w \cdot f$$

не годится, так как область значений от $-\infty$ до $+\infty$

Линейная комбинация 2

1) Делаем область значений положительной:

$$\exp \sum_i w_i f_i$$

2) Нормализуем

$$p(c|x) = \frac{1}{Z} \exp \sum_i w_i f_i$$

где $Z = \sum_c \exp(\sum_{i=1}^N w_i f_i)$

Логистическая регрессия

- ▶ считаем признаки бинарными: принимает значение 0 или 1 (индикаторная функция)
- ▶ признак – функция не только наблюдения x , но и класса c

$$p(c|x) = \frac{\exp(\sum_{i=1}^N w_i f_i(c, x))}{\sum_{c' \in C} \exp(\sum_{i=1}^N w_i f_i(c', x))}$$

Признаки в логистической регрессии

Задача - анализ тональности отзывов о товарах

Примеры признаков:

$$f_1(x) = \begin{cases} 1, \text{ если "удобный"} \in x \ \& \ c = + \\ 0, \text{ иначе} \end{cases}$$

$$f_2(x) = \begin{cases} 1, \text{ если "топорно"} \in x \ \& \ c = - \\ 0, \text{ иначе} \end{cases}$$

Признаки в логистической регрессии 2

Задача - сегментация текста на предложения

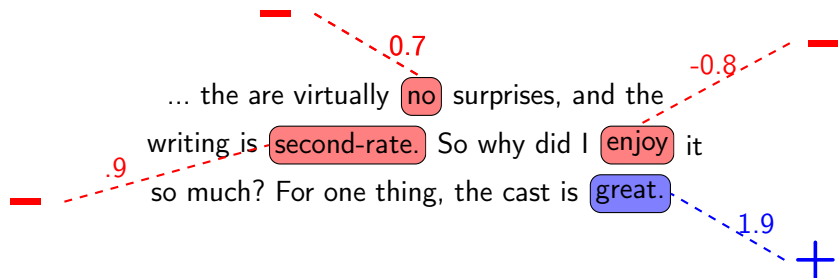
Пример признаков:

- ▶ следующее слово в верхнем регистре и $c = \text{EOS}$ (End Of Sentence)
- ▶ следующее слово в нижнем регистре и $c = \text{not-EOS}$
- ▶ следующее слово примыкает непосредственно к точке и $c = \text{not-EOS}$
- ▶ предыдущее слово \in словарю сокращений и $c = \text{not-EOS}$
- ▶ еще примеры ?

Программная реализация

- ▶ применяются шаблоны признаков
- ▶ при считывании обучающего множества по этим шаблонам генерируется индекс признаков
- ▶ при создании индекса применяется хэширование
- ▶ см. пример в Apache OpenNLP

Пример классификации



Вычисление наиболее вероятного класса

$$\begin{aligned}\hat{c} &= \arg \max_{c \in C} P(c|x) \\&= \arg \max_{c \in C} \frac{\exp(\sum_{i=1}^N w_i f_i(c, x))}{\sum_{c' \in C} \exp(\sum_{i=1}^N w_i f_i(c', x))} \\&= \arg \max_{c \in C} (\exp \sum_{i=1}^N w_i f_i(c, x)) \\&= \arg \max_{c \in C} \sum_{i=1}^N w_i f_i(c, x)\end{aligned}$$

Обучение логистической регрессии

- ▶ подбираем веса, которые делают разметку классами в обучающем множестве более вероятной
- ▶ условный метод максимального правдоподобия:

$$\hat{w} = \arg \max_w \left(\log P(y^{(j)} | x^{(j)}) \right)$$

где $(y^{(j)} | x^{(j)}) \in$ обучающему множеству

Для всего обучающего множества:

$$\hat{w} = \arg \max_w \sum_j \log P(y^{(j)} | x^{(j)})$$

Целевая функция

$$L(w) = \sum_j \log P(y^{(j)} | x^{(j)})$$

$$= \log \sum_j \frac{\exp(\sum_{i=1}^N w_i f_i(y^{(j)}, x^{(j)}))}{\sum_{y' \in Y} \exp(\sum_{i=1}^N w_i f_i(y'^{(j)}, x^{(j)}))}$$

$$= \log \sum_j \exp(\sum_{i=1}^N w_i f_i(y^{(j)}, x^{(j)})) - \log \sum_j \sum_{y' \in Y} \exp(\sum_{i=1}^N w_i f_i(y'^{(j)}, x^{(j)}))$$

→ задача оптимизации выпуклых функций

Градиентный спуск

$$L'(w) = \sum_j f_k(y^{(j)}, x^{(j)}) - \sum_j \sum_{y' \in Y} P(y'|x^{(j)}) f_k(y'^{(j)}, x^{(j)})$$

Интерпретация:

$$L'(w) = \sum_j \text{наблюдаемая частота } (f_k) - \text{ожидаемая частота } (f_k)$$

Проблема переобучения

- ▶ Если в обучающем множестве есть шумы \Rightarrow веса будут подогнаны с их учетом
- ▶ По воле случая может оказаться, что неинформативный признак будет сочетаться только с одним классом.

Выводим коэффициент регуляризации $R(w)$:

$$\hat{w} = \operatorname{argmax}_w \sum_j \log P(y^{(j)} | x^{(j)}) - \alpha R(w)$$

его предназначение - штрафовать за слишком большое значение весов

L1 и L2

L1 (евклидово расстояние):

$$R(W) = \|W\|_2^2 = \sum_{j=1}^N w_j^2$$

L2 (расстояние городских кварталов):

$$R(W) = \|W\|_1 = \sum_{i=1}^N |w_i|$$

Отбор признаков

- ▶ Многие классификаторы не предполагают внедрения коэффициента регуляризации
- ▶ Вместо этого применяется процедура отбора признаков: вычислить меру "качества" каждого признака и оставить только лучшие
- ▶ Отбор происходит на отладочном множестве

Пример - взаимная информация:

$$\begin{aligned} MI(w) = & - \sum_{i=1}^C P(c_i) \log P(c_i) \\ & + P(w) \sum_{i=1}^C P(c_i|w) \log P(c_i|w) \\ & + P(\bar{w}) \sum_{i=1}^C P(c_i|\bar{w}) \log P(c_i|\bar{w}) \end{aligned}$$

Задание 5

- ▶ Скачать корпус
<https://drive.google.com/open?id=0B4bl7YMqDnViYVo0V2FubFVh>
- ▶ Для каждой записи оставить только первый тег в качестве класса
- ▶ Реализовать классификатор по тегам с использованием модели Логистической регрессии
- ▶ Добавить признак кол-во частей речи (существительное, прилагательное, глагол, наречие)
- ▶ Извлечь наиболее информативные признаки [http://scikit-learn.org/stable/tutorial/text_analytics/working_with_text_data.ht](http://scikit-learn.org/stable/tutorial/text_analytics/working_with_text_data.html)
- ▶ Получить оценки эффективности классификатора на тестовом множестве